PROYECTO INFORME FINAL

PROYECTO DE ANALÍTICA DE DATOS

UNIVERSIDAD
DE ANTIOQUIA
1 8 0 3

INTRODUCCIÓN A LA INTELIGENCIA ARTIFICIAL

PRESENTADO POR:
SAMUEL GIL ARBOLEDA

UNIVERSIDAD DE ANTIOQUIA

DOCENTE:
RAÚL RAMOS POLLÁN

2022-1

1. INTRODUCCIÓN

1.1 PROBLEMA PREDICTIVO

En este trabajo se aborda el problema de clasificación, que tiene como objetivo predecir si un sitio web es considerado malicioso (phishing) o no, teniendo en cuenta características en la URL que normalmente tienen estos sitios. Este problema es de vital importancia debido a que estos sitios son difíciles de reconocer para gente que no tiene conocimientos en tecnología, por lo cual es necesario resolverlo mediante técnicas de aprendizaje de máquina debido a que reconocerlas manualmente podría conllevar mucho tiempo o ser un trabajo imposible, ya que la cantidad de páginas web existentes son prácticamente infinitas.

1.2 DATASET

El dataset a utilizar proviene de un repositorio de datos de machine learning llamado UCI (https://archive.ics.uci.edu/ml/datasets/phishing%20websites#). La base de datos de este proyecto es “Phishing Websites Data Set” [5], cuenta con 11055 muestras, y 31 variables, las cuales 30 son para explicar las características de una url de un sitio web, y la otra es la variable de salida “Result” la cual se encarga de decirnos si un sitio web es phishing o no.

Las variables presentes en el dataset pueden contener 2 o 3 de los siguientes valores: -1, 0 ó 1 , lo cual significa que cumplen con la condición propuesta en la variable, es sospechosa, y no la cumple, respectivamente. Además no hay datos faltantes en ninguna característica.

#	Nombre variable	Codificación
0	having_IP_Address	(categorical - signed numeric) : { -1,1 }
1	URL_Length	(categorical - signed numeric) : { 1,0,-1 }
2	Shortining_Service	(categorical - signed numeric) : { 1,-1 }
3	having_At_Symbol	(categorical - signed numeric) : { 1,-1 }
4	double_slash_redirecting	(categorical - signed numeric) : { -1,1 }
5	PrefixSuffix-	(categorical - signed numeric) : { -1,1 }
6	having_Sub_Domain	(categorical - signed numeric) : { -1,0,1 }
7	SSLfinal_State	(categorical - signed numeric) : { -1,1,0 }
8	Domain_registeration_length	(categorical - signed numeric) : { -1,1 }
9	Favicon	(categorical - signed numeric) : { 1,-1 }

10	port	(categorical - signed numeric) : { 1,-1 }
11	HTTPS_token	(categorical - signed numeric) : { -1,1 }
12	RequestURL	(categorical - signed numeric) : { 1,-1 }
13	URL_of_Anchor	(categorical - signed numeric) : { -1,0,1 }
14	Links_in_tags	(categorical - signed numeric) : { 1,-1,0 }
15	ServerFormHandler	(categorical - signed numeric) : { -1,1,0 }
16	Submitting_to_email	(categorical - signed numeric) : { -1,1 }
17	AbnormalURL	(categorical - signed numeric) : { -1,1 }
18	Redirect	(categorical - signed numeric) : { 0,1 }
19	on_mouseover	(categorical - signed numeric) : { 1,-1 }
20	RightClick	(categorical - signed numeric) : { 1,-1 }
21	popUpWidnow	(categorical - signed numeric) : { 1,-1 }
22	Iframe	(categorical - signed numeric) : { 1,-1 }
23	AgeofDomain	(categorical - signed numeric) : { -1,1 }
24	DNSRecord	(categorical - signed numeric) : { -1,1 }
25	web_traffic	(categorical - signed numeric) : { -1,0,1 }
26	PageRank	(categorical - signed numeric) : { -1,1 }
27	GoogleIndex	(categorical - signed numeric) : { 1,-1 }
28	LinksPointingToPage	(categorical - signed numeric) : { 1,0,-1 }
29	Statistical_report	(categorical - signed numeric) : { -1,1 }
30	Result	(categorical - signed numeric) : { -1,1 }

Fig 1. Columnas del dataset

1.3 MÉTRICAS

Para evaluar el sistema se van a usar las siguientes métricas de evaluación: accuracy y f1 score. Siendo accuracy la medida principal.

Por otra parte, en cuanto a la métrica de negocio, se tiene interés en que las predicciones sean lo suficientemente confiables para saber si un sitio web es de pishing o no. Con esta información un navegador de internet podría evitar que sus usuarios entren a estos sitios maliciosos solo leyendo la página a la cual se dirigen.

1.4 DESEMPEÑO ESPERADO

Lo que se esperaría de un modelo de este tipo es obtener una predicción con bastante desempeño (más de un 80% de precisión) , porque no sería viable tener muchos falsos positivos, ya que bloquear constantemente las páginas de un usuario de un navegador podría hacer que este deje de usarlo. En un ambiente productivo sería usado como filtro para evitar que los usuarios entren a las páginas que sean sospechosas.

2. EXPLORACIÓN DESCRIPTIVA DEL DATASET

La base de datos de este proyecto es “Phishing Websites Data Set”[1], cuenta con 11055 muestras, y 31 variables, las cuales 30 son para explicar las características de una url de un sitio web, y la otra es la variable de salida “Result” la cual se encarga de decirnos si un sitio web es phishing o no. La distribución de las clases es de 6157 muestras para la clase 1 (no phishing) y 4898 muestras para la clase -1 (phishing), por lo cual es un problema balanceado al no tener una diferencia significativa entre el número de muestras de una clase con respecto a la otra.

Para evaluar el sistema se usaron las siguientes medidas de evaluación: accuracy y f1 score. Siendo accuracy la medida principal.

Se procedió entonces en una primera instancia a realizar la respectiva exploración y limpieza de los datos del dataset:

Out[ ]:

	having_IP_Address	URL_Length	Shortining_Service	having_At_Symbol	double_slash_redirecting	Prefix_Suffix	having_Sub_Domain	SSLfinal_State	Domain_registeration_length	F
0	-1	1	1	1	-1	-1	-1	-1	-1	
1	1	1	1	1	1	-1	0	1	-1	
2	1	0	1	1	1	-1	-1	-1	-1	
3	1	0	1	1	1	-1	-1	-1	1	
4	1	0	-1	1	1	-1	1	1	-1	

5 rows × 31 columns

Dimensiones del dataset:

In [ ]:
```
data.shape
```

Out[ ]:
```
(11055, 31)
```

Fig 2. Dataframe del dataset

En las imágenes que se muestran a continuación, se evidencia que no hay presencia de datos nulos o faltantes. **Nota:** Si bien para el proyecto se pedía una un porcentaje específico de datos nulos, por temas de tiempo no se pudieron simular correctamente.

```
In [ ]: data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11055 entries, 0 to 11054
Data columns (total 31 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   having_IP_Address            11055 non-null  int64
 1   URL_Length                   11055 non-null  int64
 2   Shortining_Service           11055 non-null  int64
 3   having_At_Symbol             11055 non-null  int64
 4   double_slash_redirecting     11055 non-null  int64
 5   Prefix_Suffix                11055 non-null  int64
 6   having_Sub_Domain            11055 non-null  int64
 7   SSLfinal_State               11055 non-null  int64
 8   Domain_registeration_length  11055 non-null  int64
 9   Favicon                      11055 non-null  int64
 10  port                         11055 non-null  int64
 11  HTTPS_token                  11055 non-null  int64
 12  Request_URL                  11055 non-null  int64
 13  URL_of_Anchor                11055 non-null  int64
 14  Links_in_tags                11055 non-null  int64
 15  SFH                          11055 non-null  int64
 16  Submitting_to_email          11055 non-null  int64
 17  Abnormal_URL                 11055 non-null  int64
 18  Redirect                     11055 non-null  int64
 19  on_mouseover                 11055 non-null  int64
 20  RightClick                   11055 non-null  int64
 21  popUpWidnow                  11055 non-null  int64
 22  Iframe                       11055 non-null  int64
 23  age_of_domain                11055 non-null  int64
 24  DNSRecord                    11055 non-null  int64
 25  web_traffic                  11055 non-null  int64
 26  Page_Rank                    11055 non-null  int64
 27  Google_Index                 11055 non-null  int64
 28  Links_pointing_to_page       11055 non-null  int64
 29  Statistical_report           11055 non-null  int64
 30  Result                       11055 non-null  int64
dtypes: int64(31)
memory usage: 2.6 MB
```

Fig 3. Datos nulos

```
Out[ ]: having_IP_Address              0
        URL_Length                    0
        Shortining_Service            0
        having_At_Symbol              0
        double_slash_redirecting      0
        Prefix_Suffix                 0
        having_Sub_Domain             0
        SSLfinal_State                0
        Domain_registeration_length   0
        Favicon                       0
        port                          0
        HTTPS_token                   0
        Request_URL                   0
        URL_of_Anchor                 0
        Links_in_tags                 0
        SFH                           0
        Submitting_to_email           0
        Abnormal_URL                  0
        Redirect                      0
        on_mouseover                  0
        RightClick                    0
        popUpWidnow                   0
        Iframe                        0
        age_of_domain                 0
        DNSRecord                     0
        web_traffic                   0
        Page_Rank                     0
        Google_Index                  0
        Links_pointing_to_page        0
        Statistical_report            0
        Result                        0
        dtype: int64
```

Fig 4. Datos faltantes

La explicación de cada columna se encuentra en la documentación del dataset en el siguiente link: https://archive.ics.uci.edu/ml/machine-learning-databases/00327/Phishing%20Websites%20Features.docx, es bastante extensa, por lo que no se añade a este

documento.
El nombre de las columnas presentes en el dataset son las siguientes:

```
In [ ]: data.columns

Out[ ]: Index(['having_IP_Address', 'URL_Length', 'Shortining_Service',
       'having_At_Symbol', 'double_slash_redirecting', 'Prefix_Suffix',
       'having_Sub_Domain', 'SSLfinal_State', 'Domain_registeration_length',
       'Favicon', 'port', 'HTTPS_token', 'Request_URL', 'URL_of_Anchor',
       'Links_in_tags', 'SFH', 'Submitting_to_email', 'Abnormal_URL',
       'Redirect', 'on_mouseover', 'RightClick', 'popUpWidnow', 'Iframe',
       'age_of_domain', 'DNSRecord', 'web_traffic', 'Page_Rank',
       'Google_Index', 'Links_pointing_to_page', 'Statistical_report',
       'Result'],
      dtype='object')
```

Fig 5. Columnas del dataset

Adicionalmente, se decidió eliminar la columna 'ID' ya que esta no es una variable que sea relevante para el análisis.

```
In [ ]: del data["id"]
        data.head()
```

Fig 6. Eliminación columna ‘ID’

2.1 NORMALIZACIÓN, BALANCEO DE LOS DATOS y TRAIN TEST SPLIT

En la exploración del dataset, se evidenció que no existe un desbalance en los datos con un total de 11055 muestras, 6157 muestras para la clase 1 (no phishing) y 4898 muestras para la clase -1 (phishing).

```
Out[ ]: <matplotlib.axes._subplots.AxesSubplot at 0x7fa68b6e71d0>
```

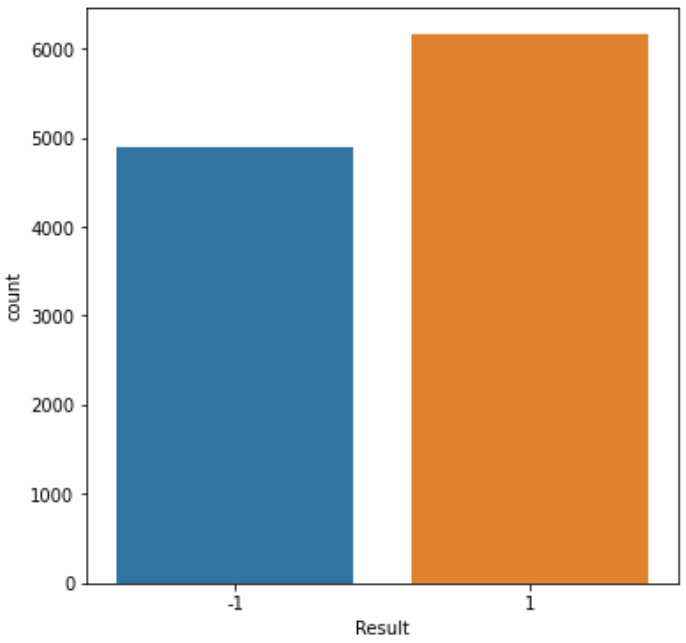

Fig 7. balance en los datos

Se dividió el dataset en dos bloques destinados al entrenamiento de los datos y validación del modelo:

Fig 8. Train Test Split

3. ALGORITMOS DE PREDICCIÓN

Se seleccionaron los algoritmos: Decision Tree y Random Forest para realizar el respectivo entrenamiento de los datos y consecuentemente generar modelos predictivos.

3.1 HIPER PARÁMETROS PARA DOS ALGORITMOS PREDICTIVOS

Con la finalidad de encontrar los mejores hiper parámetros para los algoritmos predictivos seleccionados: Decision Tree y Random Forest, se procedió a iterar en cada fold el hiper parámetro a analizar para así obtener la eficiencia de entrenamiento y de test de cada uno. Adicionalmente, se empleó el método de validación cruzada K-Fold para distribuir los datos de testeo y entrenamiento de manera equitativa.

3.1.1 DECISION TREE

Para este algoritmo se usó el hiper parámetro de profundidad del árbol,se usaron distintas profundidades del árbol (3,10,20 y 50 veces).

En la siguiente imagen se logra ver el código empleado para hallar los mejores hiper parámetros en el algoritmo Decision Tree:

```python
from sklearn.model_selection import StratifiedKFold
from sklearn.model_selection import KFold
from sklearn.tree import DecisionTreeClassifier
def algoritmo_dt(depths,X, Y):
    """función que realiza experimentos de árboles de decisión
    depths: list[int] lista con la profundidad de árboles a experimentar
    normalize bool: indica si se aplica normalización a los datos
    X: matriz con las características
    Y: matriz de numpy con etiquetas
    retorna: dataframe con:
        - profundidad de los árboles
        - eficiencia con datos de entrenamiento
        - desviación estándar con datos de entrenamiento
        - eficiencia con datos de prueba
        - desviación estándar con datos de prueba
    """
    folds = 4
    skf = KFold(n_splits=folds)
    resultados = pd.DataFrame()
    idx = 0
    for depth in depths:
        ## para almacenar los errores intermedios
        EficienciaTrain = []
        EficienciaVal = []
        for train, test in skf.split(X, Y):
            Xtrain = X[train,:]
            Ytrain = Y[train]
            Xtest = X[test,:]
            Ytest = Y[test]

            #Se llama la función para crear y entrenar el modelo usando los datos de entrenamiento
            modelo = DecisionTreeClassifier(max_depth=depth)
            modelo = modelo.fit(Xtrain, Ytrain)
            #Se predice con muestras de entrenamiento
            Ytrain_pred = modelo.predict(Xtrain)
            #Se predice con muestras de pruebas
            Ytest = modelo.predict(Xtest)
            #Evaluamos las predicciones del modelo con los datos de test
            EficienciaTrain.append(np.mean(Ytrain_pred.ravel() == Ytrain.ravel()))
            EficienciaVal.append(np.mean(Ytest.ravel() == Ytest.ravel()))

        resultados.loc[idx,'Profundidad del árbol'] = depth
        resultados.loc[idx,'Eficiencia con datos de entrenamiento'] = np.mean(EficienciaTrain)
        resultados.loc[idx,'Desviación estándar con datos de entrenamiento'] = np.std(EficienciaTrain)
        resultados.loc[idx,'Eficiencia con datos de prueba'] = np.mean(EficienciaVal)
        resultados.loc[idx,'Desviación estándar con datos de prueba'] = np.std(EficienciaVal)
        idx= idx +1

    return (resultados)
```

Fig 9. Código hiper parámetros DT.

Se puede observar que para el algoritmo Decision Tree los mejores resultados se obtienen con una profundidad de árbol de 50.

```
[ ] resultados_dt = experimentar_dt([3,10,20,50],MinMaxScaler().fit_transform(X), Y)
    resultados_dt
```

	profundidad del arbol	eficiencia de entrenamiento	desviacion estandar entrenamiento	eficiencia de prueba	desviacion estandar prueba	accuracy	f1_score
0	3.0	0.908227	0.001163	0.904029	0.011213	0.904029	0.915764
1	10.0	0.958591	0.001634	0.943825	0.006790	0.943825	0.949381
2	20.0	0.989326	0.000761	0.962272	0.019184	0.962272	0.966199
3	50.0	0.989889	0.000318	0.962543	0.019835	0.962543	0.966425

Fig 10. Resultados - DT

Después se realiza la curva de aprendizaje, dando el siguiente resultado:

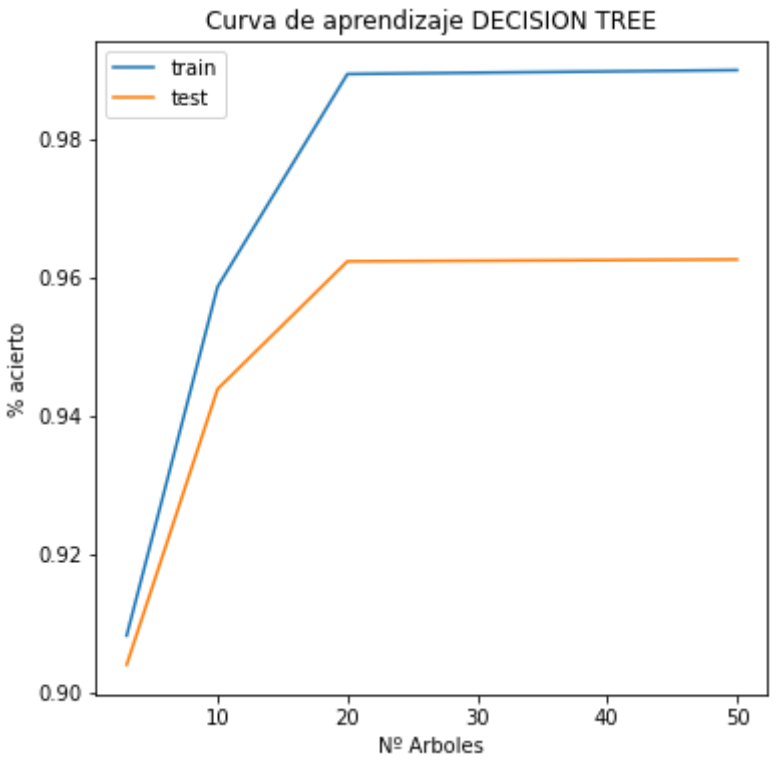

Fig 11. Curva de aprendizaje - DT

Como se puede ver en la gráfica la línea de entrenamiento está muy por encima de la prueba, lo que indicaría una alta varianza o tener **sobreajuste**. Lo que podría solucionar esto puede ser añadir más datos o extraer las variables menos significativas.

3.1.2 RANDOM FOREST

Para este algoritmo se usó el hiper parámetro de número de árboles, se usaron distintas profundidades del árbol (5,10,20,100 y 150 árboles).

En la siguiente imagen se logra ver el código empleado para hallar los mejores hiper parámetros en el algoritmo Random forest:

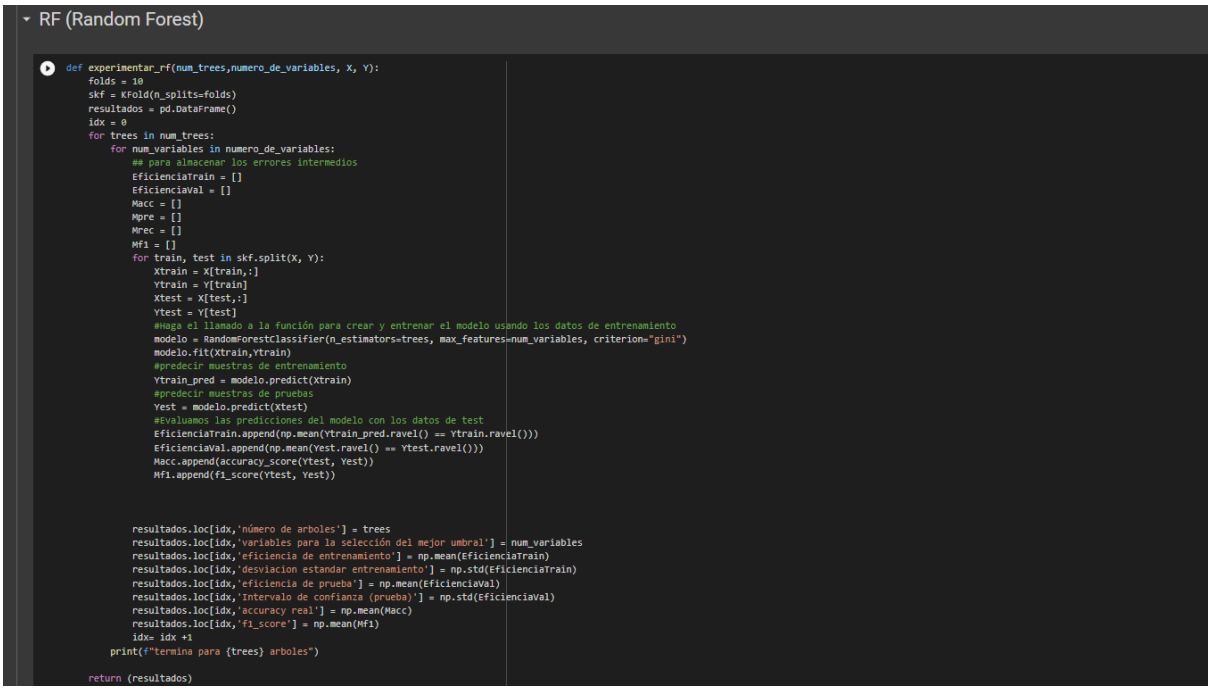

```
RF (Random Forest)

def experimentar_rf(num_trees,numero_de_variables, X, Y):
    folds = 10
    skf = KFold(n_splits=folds)
    resultados = pd.DataFrame()
    idx = 0
    for trees in num_trees:
        for num_variables in numero_de_variables:
            ## para almacenar los errores intermedios
            EficienciaTrain = []
            EficienciaVal = []
            Macc = []
            Mpre = []
            Mrec = []
            Mf1 = []
            for train, test in skf.split(X, Y):
                Xtrain = X[train,:]
                Ytrain = Y[train]
                Xtest = X[test,:]
                Ytest = Y[test]
                #Haga el llamado a la función para crear y entrenar el modelo usando los datos de entrenamiento
                modelo = RandomForestClassifier(n_estimators=trees, max_features=num_variables, criterion="gini")
                modelo.fit(Xtrain,Ytrain)
                #predecir muestras de entrenamiento
                Ytrain_pred = modelo.predict(Xtrain)
                #predecir muestras de pruebas
                Yest = modelo.predict(Xtest)
                #Evaluamos las predicciones del modelo con los datos de test
                EficienciaTrain.append(np.mean(Ytrain_pred.ravel() == Ytrain.ravel()))
                EficienciaVal.append(np.mean(Yest.ravel() == Ytest.ravel()))
                Macc.append(accuracy_score(Ytest, Yest))
                Mf1.append(f1_score(Ytest, Yest))



            resultados.loc[idx,'número de arboles'] = trees
            resultados.loc[idx,'variables para la selección del mejor umbral'] = num_variables
            resultados.loc[idx,'eficiencia de entrenamiento'] = np.mean(EficienciaTrain)
            resultados.loc[idx,'desviacion estandar entrenamiento'] = np.std(EficienciaTrain)
            resultados.loc[idx,'eficiencia de prueba'] = np.mean(EficienciaVal)
            resultados.loc[idx,'Intervalo de confianza (prueba)'] = np.std(EficienciaVal)
            resultados.loc[idx,'accuracy real'] = np.mean(Macc)
            resultados.loc[idx,'f1_score'] = np.mean(Mf1)
            idx= idx +1
        print(f"termina para {trees} arboles")

    return (resultados)
```

Fig 12. Código hiper parámetros RF.

Se puede observar que para el algoritmo Random forest los mejores resultados se obtienen con una cantidad de árboles de 50.

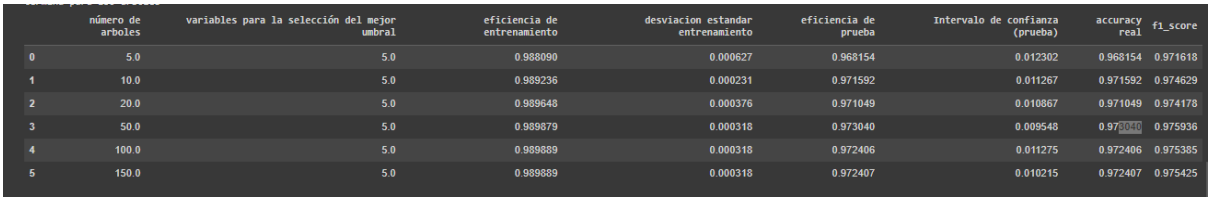

	número de arboles	variables para la selección del mejor umbral	eficiencia de entrenamiento	desviacion estandar entrenamiento	eficiencia de prueba	Intervalo de confianza (prueba)	accuracy real	f1_score
0	5.0	5.0	0.988090	0.000627	0.968154	0.012302	0.968154	0.971618
1	10.0	5.0	0.989236	0.000231	0.971592	0.011267	0.971592	0.974629
2	20.0	5.0	0.989648	0.000376	0.971049	0.010867	0.971049	0.974178
3	50.0	5.0	0.989879	0.000318	0.973040	0.009548	0.973040	0.975936
4	100.0	5.0	0.989889	0.000318	0.972406	0.011275	0.972406	0.975385
5	150.0	5.0	0.989889	0.000318	0.972407	0.010215	0.972407	0.975425

Fig 13. Resultados - RF

Después se realiza la curva de aprendizaje, dando el siguiente resultado:

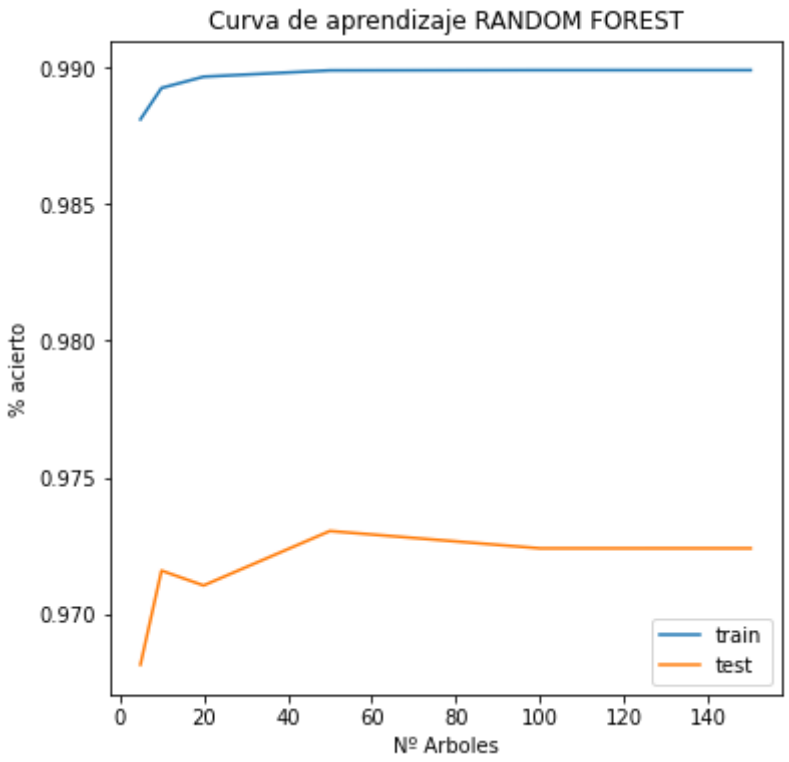

Fig 14. Curva de aprendizaje - RF

Como se puede ver en la gráfica la línea de entrenamiento está muy por encima de la prueba, lo que indicaría una alta varianza o tener **sobreajuste**. Lo que podría solucionar esto puede ser añadir más datos o extraer las variables menos significativas.

3.2 HIPER PARÁMETROS PARA DOS ALGORITMOS PREDICTIVOS + NO SUPERVISADO PCA

Con la finalidad de encontrar los mejores hiper parámetros para los algoritmos predictivos previamente mencionados más el algoritmo no supervisado (PCA), se procedió a iterar en cada fold el hiper parámetro. Además de hacer una transformación PCA. Luego se obtuvo la eficiencia de entrenamiento y de testeo para cada combinación.

3.2.1 DECISION TREE

En la siguiente imágen se puede observar el código empleado para el caso de los algoritmos Decision Tree + PCA:

PCA EN DT

```
def experimentar_dt_PCA(num_componentes,depths,X, Y):
      folds = 4
      skf = KFold(n_splits=folds)
      resultados = pd.DataFrame()
      idx = 0
      for num_comp in num_componentes:
        for depth in depths:
            Mf1 = []
            EficienciaTrain = []
            EficienciaVal = []
            for train, test in skf.split(X, Y):
                Xtrain = X[train,:]
                Ytrain = Y[train]
                Xtest = X[test,:]
                Ytest = Y[test]
                pca = PCA(n_components=num_comp)
                pca.fit(Xtrain)
                Xtrain = pca.transform(Xtrain)
                Xtest = pca.transform(Xtest)
                modelo = DecisionTreeClassifier(max_depth=depth)
                modelo = modelo.fit(Xtrain, Ytrain)
                Ytrain_pred = modelo.predict(Xtrain)
                Yest = modelo.predict(Xtest)
                EficienciaTrain.append(np.mean(Ytrain_pred.ravel() == Ytrain.ravel()))
                EficienciaVal.append(np.mean(Yest.ravel() == Ytest.ravel()))
                Mf1.append(f1_score(Ytest, Yest))

            resultados.loc[idx,'PCA componentes'] = num_comp
            resultados.loc[idx,'eficiencia de entrenamiento'] = np.mean(EficienciaTrain)
            resultados.loc[idx,'desviacion estandar entrenamiento'] = np.std(EficienciaTrain)
            resultados.loc[idx,'eficiencia de prueba'] = np.mean(EficienciaVal)
            resultados.loc[idx,'desviacion estandar prueba'] = np.std(EficienciaVal)
            resultados.loc[idx,'f1_score'] = np.mean(Mf1)
            idx= idx +1

      return (resultados)
```

Fig 15. Código DT + PCA

```
DTresultadosPCA = experimentar_dt_PCA([1,2,3,4,5,6,7,8,9,10,11,12,13,14,15,17,18,19,20,21,22,23,24,25,26,27,28,29],[20], X, Y)
DTresultadosPCA
```

	PCA componentes	eficiencia de entrenamiento	desviacion estandar entrenamiento	eficiencia de prueba	desviacion estandar prueba	f1_score
0	1.0	0.855331	0.039347	0.689991	0.129403	0.740445
1	2.0	0.976933	0.006208	0.816633	0.108246	0.836508
2	3.0	0.981969	0.004744	0.845671	0.095369	0.861211
3	4.0	0.989205	0.000727	0.858875	0.099309	0.875227
4	5.0	0.989929	0.000685	0.887731	0.087331	0.903298
5	6.0	0.989688	0.001124	0.896054	0.080457	0.908940
6	7.0	0.989658	0.001014	0.896419	0.073406	0.907298
7	8.0	0.989658	0.001014	0.898680	0.069955	0.910145
8	9.0	0.989899	0.000833	0.901847	0.069923	0.913555
9	10.0	0.989809	0.000793	0.905466	0.064216	0.915551
10	11.0	0.989628	0.001027	0.905375	0.065635	0.915550
11	12.0	0.989628	0.001148	0.904832	0.065195	0.915052
12	13.0	0.989386	0.001109	0.897504	0.071879	0.908304
13	14.0	0.989386	0.001109	0.899946	0.069642	0.910777
14	15.0	0.989085	0.001355	0.899041	0.073181	0.910150
15	17.0	0.989115	0.001331	0.908088	0.062501	0.918321
16	18.0	0.989417	0.001094	0.899313	0.070759	0.911266
17	19.0	0.989628	0.000915	0.899403	0.072526	0.911196
18	20.0	0.989055	0.000867	0.901574	0.070512	0.912904
19	21.0	0.989025	0.000927	0.901845	0.070513	0.913035
20	22.0	0.989115	0.000912	0.905645	0.067217	0.916402
21	23.0	0.989055	0.000884	0.906550	0.065709	0.917174
22	24.0	0.989417	0.000750	0.903564	0.068678	0.915284
23	25.0	0.989417	0.000750	0.905736	0.065797	0.917055
24	26.0	0.989567	0.000872	0.903294	0.067116	0.915289
25	27.0	0.989567	0.000872	0.905374	0.064330	0.916885
26	28.0	0.989567	0.000872	0.907183	0.063574	0.918152
27	29.0	0.989567	0.000872	0.904379	0.065943	0.915910

Fig 16. Resultados DT + PCA.

Se puede observar que en este caso los mejores resultados se obtienen con con un número de componentes de 15.

Después se realiza la curva de aprendizaje, dando el siguiente resultado:

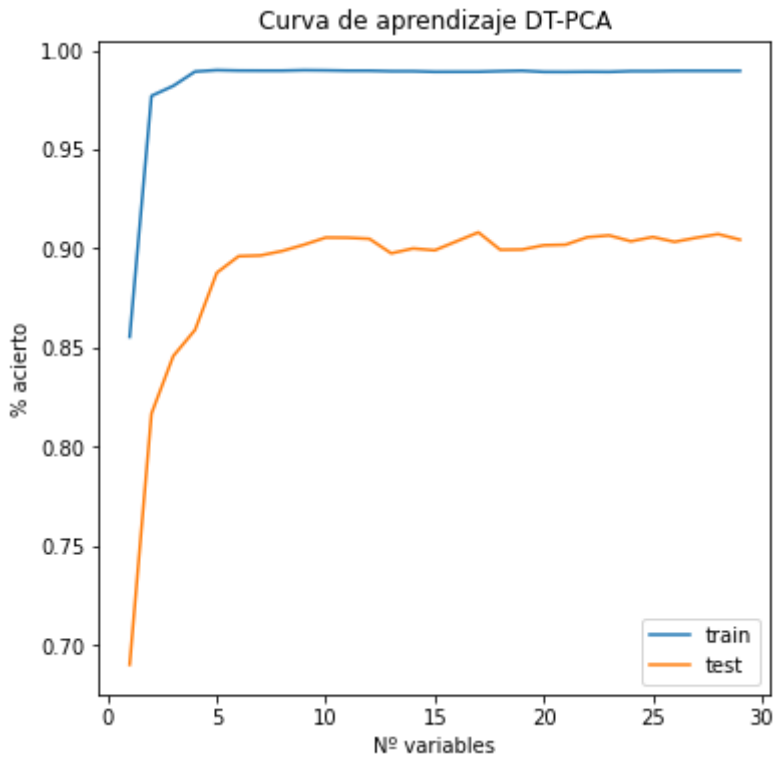

Fig 17. Curva de aprendizaje - DT + PCA

Como se puede ver en la gráfica la línea de entrenamiento está muy por encima de la prueba, además el porcentaje de acierto está por debajo del algoritmo sin pca, por lo que le pca empeoró la precisión. También se puede observar una alta varianza o tener **sobreajuste**. Lo que podría solucionar esto puede ser añadir más datos o extraer las variables menos significativas.

3.2.2 RANDOM FOREST

Código empleado para el caso de los algoritmos Random Forest + PCA:

```
[ ]  def experimentar_rf_PCA(num_componentes, X, Y):
        folds = 10
        skf = StratifiedKFold(n_splits=folds)
        resultados = pd.DataFrame()
        idx = 0
        for num_comp in num_componentes:

            EficienciaTrain = []
            EficienciaVal = []
            Mf1 = []
            for train, test in skf.split(X, Y):
                Xtrain = X[train,:]
                Ytrain = Y[train]
                Xtest = X[test,:]
                Ytest = Y[test]

                pca = PCA(n_components=num_comp)
                pca.fit(Xtrain)
                Xtrain = pca.transform(Xtrain)
                Xtest = pca.transform(Xtest)
                modelo = RandomForestClassifier(n_estimators=50, criterion="gini")
                modelo.fit(Xtrain, Ytrain)
                Ytrain_pred = modelo.predict(Xtrain)
                Yest = modelo.predict(Xtest)
                EficienciaTrain.append(np.mean(Ytrain_pred.ravel() == Ytrain.ravel()))
                EficienciaVal.append(np.mean(Yest.ravel() == Ytest.ravel()))
                Mf1.append(f1_score(Ytest, Yest))

            resultados.loc[idx,'PCA componentes'] = num_comp
            resultados.loc[idx,'eficiencia de entrenamiento'] = np.mean(EficienciaTrain)
            resultados.loc[idx,'desviacion estandar entrenamiento'] = np.std(EficienciaTrain)
            resultados.loc[idx,'eficiencia de prueba'] = np.mean(EficienciaVal)
            resultados.loc[idx,'desviacion estandar prueba'] = np.std(EficienciaVal)
            resultados.loc[idx,'f1_score'] = np.mean(Mf1)
            idx= idx +1

        return (resultados)
```

Fig 18. Código RF + PCA

```
RFresultadosPCA = experimentar_rf_PCA([1,2,3,4,5,6,7,8,9,10,11,12,13,14,15,17,18,19,20,21,22,23,24,25,26,27,28,29],X, Y)
RFresultadosPCA
```

	PCA componentes	eficiencia de entrenamiento	desviacion estandar entrenamiento	eficiencia de prueba	desviacion estandar prueba	f1_score
0	1.0	0.987869	0.000312	0.831800	0.098498	0.852786
1	2.0	0.989658	0.000501	0.897939	0.059584	0.910552
2	3.0	0.989809	0.000328	0.919202	0.047399	0.928127
3	4.0	0.989738	0.000349	0.935851	0.036957	0.943209
4	5.0	0.989798	0.000340	0.947070	0.031057	0.953205
5	6.0	0.989829	0.000348	0.953405	0.025271	0.958571
6	7.0	0.989819	0.000345	0.957024	0.021661	0.961685
7	8.0	0.989819	0.000362	0.956391	0.022697	0.961089
8	9.0	0.989829	0.000314	0.957748	0.022064	0.962339
9	10.0	0.989859	0.000335	0.958291	0.021067	0.962795
10	11.0	0.989869	0.000336	0.960282	0.018468	0.964577
11	12.0	0.989859	0.000332	0.961186	0.019062	0.965410
12	13.0	0.989839	0.000313	0.960101	0.019335	0.964529
13	14.0	0.989849	0.000371	0.960644	0.018382	0.964993
14	15.0	0.989819	0.000337	0.961006	0.017753	0.965324
15	17.0	0.989859	0.000347	0.963086	0.018544	0.967088
16	18.0	0.989879	0.000339	0.961911	0.017085	0.966125
17	19.0	0.989879	0.000342	0.961820	0.017292	0.966012
18	20.0	0.989859	0.000341	0.965621	0.014905	0.969359
19	21.0	0.989849	0.000333	0.964715	0.017082	0.968590
20	22.0	0.989889	0.000343	0.965620	0.015317	0.969399
21	23.0	0.989879	0.000330	0.964716	0.016302	0.968596
22	24.0	0.989879	0.000342	0.966887	0.014612	0.970532
23	25.0	0.989859	0.000329	0.965529	0.017844	0.969349
24	26.0	0.989869	0.000330	0.965620	0.016048	0.969448
25	27.0	0.989889	0.000343	0.966435	0.015229	0.970081
26	28.0	0.989879	0.000333	0.966254	0.015205	0.969983
27	29.0	0.989839	0.000349	0.965982	0.015329	0.969693

Fig 19. Resultados RF + PCA.

Se puede observar que en este caso los mejores resultados se obtienen con con un número de componentes de 22.

Después se realiza la curva de aprendizaje, dando el siguiente resultado:

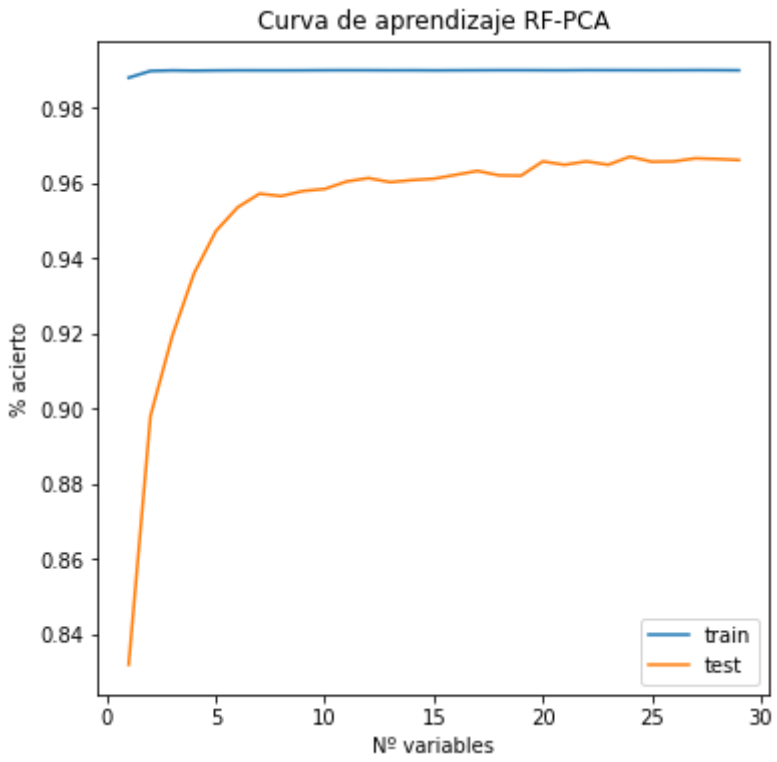

Fig 20. Curva de aprendizaje - RF + PCA

Como se puede ver en la gráfica la línea de entrenamiento está por encima de la prueba, pero al parecer se disminuyó la distancia que las dos líneas tenían sin el algoritmo pca, por lo que el pca disminuyó la varianza, esto aunque aún haya un poco de **sobreajuste**.

4. RECOMENDACIONES PARA MEJORAR EL DESEMPEÑO

Para mejorar el desempeño obtenido se podría intentar seguir alguna de las siguientes recomendaciones:

- Incluir otros tipos de algoritmos de machine learning como por ejemplo: redes neuronales, máquinas de soporte vectorial, entre otros.
- Realizar pruebas con otros hiper parámetros en los algoritmos de Decisión tree y Random Forest, se podría tener mejores resultados.
- Realizar un estudio para definir cuáles variables son significativas para el modelo, se podría intentar por ejemplo con la técnica de sequential feature selection.

5. RETOS Y CONDICIONES PARA DESPLEGAR EN PRODUCCIÓN EL MODELO

Uno de los retos más grandes que supondría un despliegue de este modelo,

sería la extracción de los datos que dependen de bases de datos de terceros. Por cada url que la aplicación escanee, se tendría que ir a buscar a ciertas bases de datos y extraer información como: la antigüedad de la página, ver si está en alguna lista negra en algún sitio web, consultar si la página tiene los permisos correctos, etc…

Para desplegar el modelo en producción se haría uso de un servicio mediante una api que responda a la solicitud vía POST con la mayoría de las variables de entrada como parámetros en la solicitud. De esta manera la respuesta sería la predicción con la probabilidad de que la página sea phishing o no para alertar al cliente.

Finalmente, para monitorear el desempeño se optaría por almacenar en registros los datos de las predicciones obtenidas y los futuros valores reales obtenidos. Esto con el objetivo de llevar el monitoreo del rendimiento y de cómo se está comportando el modelo.

REFERENCIAS

1. UCI Machine Learning Repository: Phishing Websites Data Set. [Online]. Available: https://archive.ics.uci.edu/ml/datasets/phishing+websites .